Emanuele Magon (909482)

Relatore: Marco Anisetti

Corso di laurea in
SICUREZZA DEI SISTEMI E DELLE RETI INFORMATICHE

UNIVERSITÀ DEGLI STUDI DI MILANO
SCIENZE E TECNOLOGIE

Riassunto dell'elaborato

SENSITIVE DATA DETECTOR: IDENTIFICAZIONE AUTOMATICA DI DATI SENSIBILI ALL'INTERNO DI LOG

1. Ente presso cui è stato svolto il lavoro di stage

Il tirocinio interno è stato svolto presso il Dipartimento di Informatica dell`Università degli Studi di Milano, sotto la supervisione del Prof. Marco Anisetti e del Dott. Antongiacomo Polimeno.

2. Contesto iniziale

Il contesto di partenza era caratterizzato dalla presenza di elevati volumi di log, generati da micro-servizi eterogenei appartenenti a una piattaforma di domotica e smart city, con formati e contenuti non uniformi. In tale scenario, i log possono contenere dati sensibili quali indirizzi email, token di autenticazione e coordinate geografiche, con conseguenti implicazioni in termini di tutela della privacy e di conformità normativa. Nel contesto operativo considerato non era sempre possibile intervenire direttamente sul codice sorgente dei sistemi che producono i log; si è reso pertanto necessario progettare un sistema esterno in grado di analizzare automaticamente i messaggi e segnalare le occorrenze critiche.

3. Obiettivi del lavoro

Gli obiettivi prefissati all`avvio del lavoro erano i seguenti: - progettare un sistema automatico per identificare dati sensibili nei log; - bilanciare accuratezza e scalabilità, riducendo i falsi negativi; - integrare la soluzione in un`infrastruttura di log management già in uso (Graylog); - valutare in modo quantitativo l`efficacia dei Large Language Model su dataset annotati; - produrre una base evolutiva riutilizzabile in ambiente di produzione.

4. Descrizione lavoro svolto

In una fase preliminare si è condotta un`analisi dello stato dell`arte riguardante strumenti e approcci esistenti per l`identificazione di dati sensibili nei log. Il lavoro di sviluppo è stato condotto secondo un approccio iterativo e incrementale, articolato in tre versioni successive del sistema

Sensitive Data Detector. Nel corso dello sviluppo sono stati inoltre confrontati diversi LLM su piattaforme hardware differenti (Apple M1 Max e AMD RX6950XT), valutando i compromessi tra tempi di inferenza e qualità del rilevamento. La prima fase ha prodotto un proof-of-concept in modalità batch su file di log, finalizzato a validare la fattibilità dell`approccio basato su LLM. Ciò ha messo in evidenza i primi limiti pratici, con particolare riferimento alla scalabilità e alla misurabilità oggettiva delle prestazioni. Nella seconda fase è stato introdotto un flusso di elaborazione riga per riga, con modelli personalizzati mediante Modelfile e un dataset corredato di ground truth. Questo ha consentito l`implementazione di un processo di valutazione automatica fondato su metriche di classificazione binaria (TP, TN, FP, FN) e su metriche derivate (accuracy, precision, specificity, recall). Nella terza e ultima fase è stata realizzata l`integrazione con Graylog in modalità push (stream in tempo reale) e pull (batch incrementale), adottando programmazione asincrona e meccanismi di feedback verso la piattaforma di log management per la notifica dei rilevamenti.

5. Tecnologie coinvolte

Le principali tecnologie utilizzate nel corso dello stage sono le seguenti: - Python 3.12 per logica applicativa, scripting e integrazione; - librerie Python: ollama, asyncio, httpx, anyio, requests; - Graylog per raccolta, stream, pipeline con espressioni regolari, output e API REST; - protocollo GELF per lo scambio strutturato dei log; - Ollama per l`esecuzione locale di modelli LLM; - modelli LLM open weight personalizzati via Modelfile (llama3.1, llama3.2, mistral, mistral-nemo, qwen2.5, gemma3, deepseek-r1); - Docker e Docker Compose per l`ambiente riproducibile di test e integrazione.

6. Competenze e risultati raggiunti

Quali risultati sono stati raggiunti rispetto agli obiettivi iniziali? - È stato progettato e implementato un sistema ibrido con regex e LLM per l`identificazione di dati sensibili all`interno dei log. - È stato dimostrato il percorso evolutivo da prototipo sperimentale a soluzione integrabile in un flusso operativo reale basato su Graylog. - È stato introdotto un processo di valutazione quantitativa su dataset annotati, al fine di confrontare le prestazioni dei modelli in modo oggettivo. Quali insegnamenti si possono trarre dall`esperienza effettuata? - L`approccio ibrido consente di sfruttare la velocità e il determinismo delle espressioni regolari con la flessibilità semantica offerta dai modelli LLM. - La qualità dei prompt e la configurazione del contesto esercitano un`influenza significativa sull`affidabilità del rilevamento. - L`integrazione con i sistemi esistenti e la tracciabilità

operativa rivestono un`importanza pari a quella dell`accuratezza del modello. Quali i problemi incontrati? Quali risolti e quali no? Perché? - Problema risolto: il limite di scalabilità della prima versione è stato superato mediante l`adozione di un`elaborazione riga per riga e di un`architettura asincrona. - Problema risolto: l`assenza di metriche oggettive è stata affrontata introducendo un dataset con ground truth e un sistema di valutazione automatica nella seconda versione. - Problema aperto: un adattamento più approfondito dei modelli al dominio specifico dei log, perseguibile in futuro mediante tecniche di fine-tuning dedicate (ad es. LoRA).

7. Bibliografia significativa

1. Ji, Y. et al. (2024). Adapting Large Language Models to Log Analysis with Interpretable Domain Knowledge. arXiv:2412.01377. 2. Beck, V. et al. (2025). System Log Parsing with Large Language Models: A Review. arXiv:2504.04877. 3. Karlsen, E. et al. (2023). Benchmarking Large Language Models for Log Analysis, Security, and Interpretation. arXiv:2311.14519. 4. Ma, Z. et al. (2024). LLMParser: An Exploratory Study on Using Large Language Models for Log Parsing. arXiv:2404.18001. 5. Kostina, A. et al. (2025). Large Language Models for Text Classification: Case Study and Comprehensive Review. arXiv:2501.08457. 6. Alassan, M. S. Y. et al. (2024). Comparison of Open-Source and Proprietary LLMs for Machine Reading Comprehension. arXiv:2406.13713. 7. White, C. et al. (2024). LiveBench: A Challenging, Contamination-Limited LLM Benchmark. arXiv:2406.19314.